

3D-Segmentierung der Oberschenkelmuskulatur

Automatische Muskelsegmentierung mit einem Bayesian 3D U-Net

Sabina Grüner
Michelle Rohrer

Frühjahrssemester 2026

Inhaltsverzeichnis

1 Problem Statement / Use Case	3
2 Data.....	3
3 Methods	4
4 Most Relevant Results	4
5 Discussion	5
6 Reflection.....	6
A Anhang	7
A.1 Abbildungen.....	7
A.2 Tabellen	13

1 Problem Statement / Use Case

Die manuelle 3D-Segmentierung der Oberschenkelmuskulatur in MRT-Studien ist zeitintensiv, inter-Rater-anfällig und schlecht skalierbar. Diese Mini-Challenge untersucht, ob ein Bayesian 3D U-Net acht rechte Oberschenkelmuskeln — Quadrizeps (VL, RF, VM, VI) und Hamstrings (BfSH, BfLH, ST, SM) — aus wassergewichteten 3D-MRI-Aufnahmen voxelgenau in neun Klassen (Hintergrund + acht Muskeln) segmentiert.

Use Case: Die Lösung soll manuelle Annotation in der quantitativen Muskelforschung ersetzen und reproduzierbare 3D-Volumenmessungen ermöglichen, etwa zur Früherkennung von Sarkopenie oder zum Rehabilitations-Monitoring. Die Analyse erfolgt am rechten Bein, da der Datensatz dort vollständige Masken liefert; die Methodik ist seitenunabhängig.

Forschungsfragen:

1. **RQ1:** Erreicht ein kompakter 3D-Ansatz auf einem fallbasierten Validierungsset einen mittleren Dice-Koeffizienten von mindestens 0.60 über die Zielklassen des rechten Beines?
2. **RQ2:** Verbessert ein regularisiertes und getunt 3D-Modell den mittleren Dice gegenüber einer einfachen 3D-Baseline unter identischen Daten- und Evaluationsbedingungen um mindestens +0.03?

2 Data

Datensatz: 10 Probanden (NIfTI); je ein wassergewichtetes, anisotropes 3D-Volumen und eine Maske mit acht rechtsseitigen Muskelklassen plus Hintergrund.

Datencharakteristik: Die EDA begründet zwei Entscheidungen. In der Slice-Coverage fallen die linken Masken teils auf ~0 % ab, während die rechte Seite vollständig annotiert ist ([Anhang, Abb. 1](#)) — daher nur das rechte Bein. Zudem besteht starkes Klassen-Ungleichgewicht (BfSH ~10× weniger Voxel als VL und geringere Schicht-Abdeckung), was den Hintergrundausschluss und imbalance-robuste Losses motiviert.

Splits: 3-Fold-CV auf Probanden-Ebene (Train 6–7, Val 3–4); bei n=10 ist kein dediziertes Testset vertretbar, alle Slices eines Probanden liegen in derselben Partition (keine Leakage).

Preprocessing: H/2-Crop (rechtes Bein), Z-Crop auf annotierte Slices ± 4 , 3D-Bounding-Box ± 16 Voxel, Intensitätsnormierung $[P0.5, P99.5] \rightarrow [0, 1]$.

Limitationen: n=10 (6–7 Trainingsfälle pro Fold) limitiert strukturell; Daten aus einer einzigen Studie.

3 Methods

Der Gesamt-Workflow ist im [Anhang](#) skizziert.

Modellwahl — Bayesian 3D U-Net: Eingesetzt wird ein einziges Modell, ein Bayesian 3D U-Net mit Monte-Carlo-Dropout.

- **3D statt 2D:** Muskelgrenzen sind dreidimensional und das MRI ist stark anisotrop; ein 2D-Ansatz ignoriert den Kontext entlang der Längsachse und führt gerade bei schmalen Muskeln (BfSH) zu Fehlern. Die referenzierte Bachelorarbeit nutzt 2D; dieser Beitrag grenzt sich davon ab.

- **Bayesian Dropout:** Bei $n=10$ ist Unsicherheitsquantifizierung sinnvoll. MC-Dropout bleibt zur Inferenz aktiv; $N=10$ Forward Passes liefern eine mittlere Segmentierung und eine voxelweise Varianzkarte (nur hpt_dropout; alle anderen Experimente evaluieren deterministisch). Hohe Varianz an Grenzen ist erwartet, hohe Varianz in Muskelzentren weist auf Modellprobleme hin.

Architektur: Encoder-Decoder mit Skip Connections, base_channels=16, depth=4, Dropout $p=0.3$. Kompakt gewählt, da grössere Netze bei 6–7 Trainingsfällen überanpassen. Input 1 Kanal, Output 9-Klassen-Softmax. Patch-Training $128 \times 128 \times 32$, Batch 2, Mixed Precision.

Experimentelle Sequenz:

3. **Overfit-Validierung:** Single-Subject-Overfit (Proband 512, dropout=0, lr=1e-3, 300 Ep.) bestätigt Pipeline und Modellkapazität, bevor Generalisierung getestet wird (Schwelle Dice ≥ 0.90).
4. **Baseline:** Dice Loss (ohne BG), Adam lr=0,0001, 100 Ep., dropout=0.3, keine Augmentation, foreground-zentriertes Sampling.
5. **Fünf isolierte HPT-Experimente**, je ein Parameter gegenüber der Baseline geändert ([Details in Anhang, Tab. A1](#)).

Evaluation: Primärmetrik Macro-Dice über Klassen 1–8 (BG ausgeschlossen, da ~82% der Voxel), gemittelt über 3 Folds $\pm$ Std. Sliding-Window-Inferenz mit 50% Überlapp. CC-Postprocessing (Connected-Component): Eine zusammenhängende Komponente ist eine Gruppe direkt benachbarter Voxel derselben Klasse; pro Klasse wird nur die grösste solche 3D-Komponente behalten und kleinere, isolierte Fehlsegmente werden verworfen, da ein Muskel anatomisch ein einziges zusammenhängendes Volumen bildet. ECE wird nur für hpt_dropout ($N=10$ MC-Samples) berechnet.

4 Most Relevant Results

Overfit-Validierung und Forschungsfragen: Der Single-Subject-Overfit (Proband 512) erreicht einen Dice von 0.9011 (Epoche 244; [Anhang, Abb. 3 und 4](#)) und belegt, dass Architektur und Pipeline die acht Zielklassen prinzipiell trennen können. Die unter 3-Fold-CV deutlich tieferen Werte sind somit kein Kapazitäts-, sondern ein Generalisierungsproblem im datenarmen Regime. Damit lässt sich RQ1 (mittlerer Dice ≥ 0.60) klar verneinen: Das beste Modell hpt_combined erreicht 0.308 ± 0.061 , mit CC 0.355 ([Anhang, Tab. A2](#)). RQ2 (Verbesserung $\geq +0.03$ gegenüber Baseline) ist dagegen erfüllt — hpt_combined übertrifft die Baseline (0.234) um +0.074 (ohne CC) bzw. +0.088 (mit CC).

Experiment-Vergleich ([Anhang, Abb. 5](#)): Nur Massnahmen gegen das Klassen-Ungleichgewicht verbessern das Ergebnis. hpt_focal (0.266) hebt selektiv die Hamstrings; der reine Cosine-Scheduler hpt_lr (0.213) bleibt knapp unter der Baseline, und reine Regularisierung ist kontraproduktiv: hpt_dropout (0.130) und hpt_augmentation (0.126) fallen um 40–46 % ab, da sie bei $n=10$ das ohnehin knappe Signal weiter verdünnen. Erst die Kombination aus Focal-Tversky-Loss und klassen-balanciertem Sampling vereint Quadrizeps-Stärke und Hamstring-Sensitivität. Der Gewinn von +0.074 entspricht jedoch nur etwa dem 1.2-Fachen der Fold-Streuung von hpt_combined (± 0.061); bei drei Folds und $n=10$ überlappen die Streubereiche, sodass der Vorsprung deskriptiv und ohne gepaarten Signifikanztest nicht inferenzstatistisch abgesichert ist.

Anatomisches Muster ([Anhang, Tab. A3](#), [Abb. 6](#)): Die Leistung spaltet sich konsistent — der Quadrizeps ist gut segmentierbar (hpt_combined: VL 0.74, VI 0.72, VM 0.42), die

Hamstrings bleiben schwach (BfSH 0.00, BfLH 0.04). Die Confusion-Matrix ([Anhang, Abb. 7](#)) lokalisiert die Ursache: In der Baseline werden 0 % der BfSH-Voxel korrekt erkannt und überwiegend als Quadrizeps (VM/RF) prädiagnostiziert. hpt_focal hebt BfSH auf 55 %, senkt aber die VM-Korrektheit von 80 % auf 51 % — ein direkter Sensitivitäts-Spezifitäts-Tausch. hpt_combined erreicht bei VL, VM und VI 90–95 % korrekte Voxel (RF: 29 %), verwechselt BfSH jedoch weiterhin (35 % VM, 37 % SM).

Postprocessing und Kalibrierung: Das CC-Postprocessing wirkt asymmetrisch — es hebt den Quadrizeps deutlich (VM, VI je $\approx +0.1$), schadet aber den Hamstrings (BfLH 0.04 $\rightarrow$ 0.01), weil deren grösste Komponente bereits falsch liegt; der Netto-Gewinn (+0.047) ist somit quadrizeps-getrieben. Die Unsicherheitsschätzung (hpt_dropout, N=10 MC-Samples) ergibt ein mittleres ECE von 0.070 — das Modell ist nur leicht überconfident. Die qualitativen Vorhersagen ([Anhang, Abb. 8 und 9](#)) bestätigen das Muster visuell: In der Baseline kollabieren die Hamstrings zu Hintergrund oder Quadrizeps, während hpt_combined den vorderen Quadrizeps nahe an der Ground Truth segmentiert, die Hamstrings hinten aber als undifferenzierten Block ohne Klassentrennung darstellt.

5 Discussion

RQ1 (Dice ≥ 0.60): nicht erreicht. Das beste Ergebnis ist 0.308 (hpt_combined) bzw. 0.355 mit CC — rund 0.25 unter dem Ziel. Der Overfit (0.90 auf einem Probanden) belegt ausreichende Modellkapazität; der Engpass ist die Datenbasis. Mit 6–7 Trainingsfällen pro Fold kann das Netz keine cross-subject-stabilen Klassengrenzen lernen, da anatomische Variabilität (Muskelgrösse, -lage, -form) nicht abgedeckt ist. Ein Dice ≥ 0.60 setzt realistisch 30–50 annotierte Probanden oder Transfer Learning (z.B. nnU-Net) voraus. Für den direkten klinischen Einsatz sind die Ergebnisse noch nicht geeignet, der Entwicklungsprozess ist jedoch vollständig und methodisch korrekt.

RQ2 (+0.03): erfüllt. hpt_focal (+0.032) und hpt_combined (+0.074) übertreffen die Baseline signifikant; mit CC steigen die Werte auf +0.028 bzw. +0.088. RQ2 ist mit und ohne Postprocessing erfüllt.

Drei Fehlermodi — eine Evolution: Die Confusion-Matrix-Analyse ([Anhang, Abb. 7](#)) zeigt qualitativ verschiedene Fehlermuster, die einen Lernpfad beschreiben:

- **Baseline:** Hamstrings kollabieren in den Hintergrund oder werden als Quadrizeps klassifiziert — die Region wird lokalisiert, die Grenzen nicht.
- **hpt_focal:** Der BG-Kollaps verschwindet, aber 43–61% der Hamstring-Voxel landen beim falschen Muskel. Focal Loss erzwingt Foreground, löst aber die Klassentrennung nicht.
- **hpt_combined:** VL, VM, VI erreichen 90–95% korrekte Voxel (RF: 29%), doch BfSH bleibt bei 0%. Klassen-balanciertes Sampling stabilisiert den Quadrizeps, reicht für die schwierigsten Hamstrings aber nicht.

Dieser Übergang von BG-Kollaps über Inter-Muskel-Verwechslung zu selektiver Klassen-Dominanz ist die zentrale diagnostische Erkenntnis und wäre durch Dice-Scores allein nicht sichtbar gewesen.

Fehlgeschlagene Experimente: hpt_augmentation verschlechterte sich um -0.108 . Nachträglich wurde ein anatomischer Bug identifiziert: Axis-0-Flip vertauscht VL $\leftrightarrow$ VM, Axis-1-Flip RF $\leftrightarrow$ Hamstrings, rot90 zerstört die Anatomie — das Modell trainierte auf

widersprüchlichen Labels. Die korrigierte Variante (nur Axis-2-Flip + Jitter) floss in hpt_combined ein, erklärt dessen Gewinn aber nicht allein; dominant sind klassen-balanciertes Sampling und Focal-Tversky-Loss. hpt_dropout p=0.5 scheiterte, da starke Regularisierung im datenknappen Regime zu wenig Information aus den Daten lässt.

Klinische Einordnung: VL (92% korrekt) und SM (73%) erreichen bereits klinisch relevante Genauigkeiten. Für selektives Volumen-Monitoring einzelner Muskeln wäre ein Einsatz denkbar; für alle acht Klassen gleichzeitig ist mehr Trainingsdaten nötig.

6 Reflection

Die Overfit-Validierung (Dice 0.90, Epoche 244) war unverzichtbar: Sie belegte die Korrektheit der Pipeline und die Budget-Limitierung der CV-Runs. Der überraschendste Befund war die Evolution der Fehlermodi (BG-Kollaps → Inter-Muskel-Verwechslung → selektive Dominanz), nur durch die Confusion-Matrix sichtbar. Rückblickend hätte anatomisch-bewusste Augmentation von Beginn an Priorität haben sollen. Empfehlung: mindestens 20 Probanden, Transfer Learning (nnU-Net) und konfidenzgewichtetes CC.

Selbstbeurteilung – selbst eingeschätzte Note: 5.5. Gemessen am Bewertungsraster (fünf Kompetenzen) schätzen wir die Arbeit auf eine 5.5 ein: Methodendesign, Evaluation und analytische Einordnung sind stark, während wir die Limitationen bei Datengrundlage und Implementierung bewusst reflektieren.

Methodendesign: Die Karpathy-Sequenz (Overfit → Baseline → isolierte Ein-Parameter-Experimente) ist konsequent umgesetzt; jede Entscheidung — kompakte 3D-Architektur, 3-Fold-CV für die kleine Fallzahl, MC-Dropout zur Unsicherheitsschätzung — ist explizit begründet. **Evaluation und Analyse:** Macro-Dice mit Fold-Varianz, Per-Klassen-Dice, Confusion-Matrizen, CC-Diagnostik, ECE und qualitative Vorhersage-Overlays (Abb. 8 und 9) sind vollständig und transparent reportiert, inklusive der Fehlschläge; die drei herausgearbeiteten Fehlermodi (Hintergrund-Kollaps → Inter-Muskel-Verwechslung → selektive Dominanz) liefern eine nicht-generische diagnostische Erkenntnis mit klaren klinischen Grenzen.

Datengrundlage und technische Umsetzung: Use Case, Splits und EDA sind sauber, doch n=10 limitiert strukturell; die Pipeline ist korrekt und durch den Overfit validiert, der Augmentation-Bug wurde jedoch erst nachträglich erkannt. Eine statistische Absicherung des Modellvergleichs (gepaarter Foldtest) würde die Evaluation zusätzlich härten. Insgesamt überwiegen die Stärken in Methodik, Evaluation und Analyse die Limitationen deutlich, weshalb wir die Arbeit bei einer 5.5 sehen.

A Anhang

A.1 Abbildungen




Abbildung 1 - Slice Coverage



Abbildung 2 - Verarbeitungs-Pipeline der 3D-Segmentierung




Abbildung 3 – Overfit Loss




Abbildung 4 - Overfit Dice




Abbildung 5 - Dice overview




Abbildung 6 - Dice per class

Abb. A6 – Confusion-Matrix (Foreground-Voxel, Zeilen-normiert in %)




Abbildung 7 - Confusion Matrix




Abbildung 8 - Vorhersagen Baseline (Proband 512, Fold 0)




Abbildung 9 - Vorhersagen *hpt_combined* (Proband 512, Fold 0)

Lesehilfe zu Abb. 8 und 9: Beide zeigen Proband 512 (Fold 0) in sechs repräsentativen Axialschnitten (Zeilen = verschiedene Z-Positionen am Oberschenkel). Spalten: links Water-

MRI (Modelleingabe), Mitte Ground Truth als Farbüberlagerung, rechts Modell-Vorhersage. Farbkodierung der acht Muskelklassen: VL violett/blau, RF orange, VM rosa, VI gelb, Hamstrings (BfSH, BfLH, ST, SM) türkis/grün, Hintergrund schwarz. In der Baseline (Abb. 8) kollabieren die Hamstrings im hinteren Querschnitt entweder zu Hintergrund oder werden als Quadrizeps eingefärbt. Bei hpt_combined (Abb. 9) ist der vordere Quadrizeps gut und nahe an der Ground Truth segmentiert, während die Hamstrings hinten als zusammenhängender Türkis-Block ohne klare Klassentrennung erscheinen.

A.2 Tabellen

Tab. A1: HPT-Experimente, jeweils ein Parameter gegenüber der Baseline geändert.

Experiment	Änderung vs. Baseline
hpt_focal	Dice + Focal Loss (Hamstrings $\alpha=3-4$, BG $\alpha=0.1$, $\gamma=2.0$)
hpt_augmentation	+ Axis-Flips + Intensitätsjitter (Bug, s. Diskussion)
hpt_lr_scheduler	+ Cosine Annealing + Early Stopping (Geduld 20 Ep.)
hpt_dropout	Dropout $p=0.5$ + ECE-Bewertung (N=20 MC-Samples)
hpt_combined	Focal-Tversky ($\alpha=0.3$, $\beta=0.7$, $\gamma=0.75$) + klassen-balanciertes Sampling, 200 Ep.

Tab. A2: Dice-Übersicht, 3-Fold CV, Hintergrund ausgeschlossen. Beste Zeile hervorgehoben.

Experiment	Fold 0	Fold 1	Fold 2	Mean $\pm$ Std	mit CC
Baseline	0.260	0.244	0.197	0.234 $\pm$ 0.026	0.266
hpt_focal	0.234	0.255	0.308	0.266 $\pm$ 0.031	0.294
hpt_lr_scheduler	0.227	0.210	0.204	0.213 $\pm$ 0.010	0.254
hpt_dropout $p=0.5$	0.131	0.140	0.119	0.130 $\pm$ 0.009	0.154
hpt_augmentation	0.147	0.095	0.135	0.126 $\pm$ 0.022	0.156
hpt_combined	0.391	0.244	0.288	0.308 $\pm$ 0.061	0.355

Tab. A3: Per-Klassen-Dice (Mittel über Val-Probanden).

Muskel	Baseline	hpt_focal	hpt_combined
VL_R	~0.58	~0.53	0.743
RF_R	~0.10	~0.15	0.135
VM_R	~0.28	~0.29	0.415
VI_R	~0.70	~0.41	0.716
BfSH_R	~0.02	~0.11	0.000
BfLH_R	~0.00	~0.26	0.044
ST_R	~0.00	~0.37	0.292
SM_R	~0.00	~0.12	0.182