

3D-Segmentierung der Oberschenkelmuskulatur

Automatische Muskelsegmentierung mit einem Bayesian 3D U-Net

Sabina Grüner
Michelle Rohrer

Inhaltsverzeichnis

1 Problem Statement / Use Case	3
2 Data.....	3
3 Methods	4
4.6 Most Relevant Results	4
5 Discussion.....	5
6 Reflection.....	6
A Anhang.....	7
A.1 Abbildungen.....	7
A.2 Tabellen	13

1 Problem Statement / Use Case

Die manuelle 3D-Segmentierung der Oberschenkelmuskulatur in MRT-Studien ist zeitintensiv, inter-Rater-anfällig und schlecht skalierbar. Diese Mini-Challenge untersucht, ob ein Bayesian 3D U-Net acht rechte Oberschenkelmuskeln — Quadrizeps (VL, RF, VM, VI) und Hamstrings (BfSH, BfLH, ST, SM) — aus wassergewichteten 3D-MRI-Aufnahmen voxelgenau in neun Klassen (Hintergrund + acht Muskeln) segmentiert.

Use Case: Die Lösung soll manuelle Annotation in der quantitativen Muskelforschung ersetzen und reproduzierbare 3D-Volumenmessungen ermöglichen, etwa zur Früherkennung von Sarkopenie oder zum Rehabilitations-Monitoring. Die Analyse erfolgt am rechten Bein, da der Datensatz dort vollständige Masken liefert; die Methodik ist seitenunabhängig.

Forschungsfragen:

1. **RQ1:** Erreicht ein kompakter 3D-Ansatz auf einem fallbasierten Validierungsset einen mittleren Dice-Koeffizienten von mindestens 0.60 über die Zielklassen des rechten Beines?
2. **RQ2:** Verbessert ein regularisiertes und getunttes 3D-Modell den mittleren Dice gegenüber einer einfachen 3D-Baseline unter identischen Daten- und Evaluationsbedingungen um mindestens +0.03?

2 Data

Datensatz: Der aufbereitete Datensatz umfasst 10 Probanden im NIfTI-Format. Jeder Fall enthält ein wassergewichtetes 3D-Volumen und eine Segmentierungsmaske.

Splits: 3-Fold Cross-Validation auf Probanden-Ebene (Train 6–7, Val 3–4). Bei $n=10$ ist kein dediziertes Testset vertretbar; die Folds dienen als Out-of-Fold-Schätzung. Alle Slices eines Probanden liegen in derselben Partition (keine Datenleakage).

Preprocessing: H/2-Crop (untere Hälfte, rechtes Bein), Z-Crop auf annotierte Slices ± 4 , 3D-Bounding-Box ± 16 Voxel, Intensitätsnormierung auf $[P0.5, P99.5]$ und $[0, 1]$.

Limitationen: Kleine Fallzahl (6–7 Trainingsfälle pro Fold) und starkes Klassen-Ungleichgewicht ([BfSH ~10× kleiner als VL](#)); Daten aus einer einzigen Studie.

3 Methods

Der Gesamt-Workflow ist im [Anhang](#) skizziert.

Modellwahl — Bayesian 3D U-Net: Eingesetzt wird ein einziges Modell, ein Bayesian 3D U-Net mit Monte-Carlo-Dropout.

- **3D statt 2D:** Muskelgrenzen sind dreidimensional und das MRI ist stark anisotrop; ein 2D-Ansatz ignoriert den Kontext entlang der Längsachse und führt gerade bei schmalen Muskeln (BfSH) zu Fehlern. Die referenzierte Bachelorarbeit nutzt 2D; dieser Beitrag grenzt sich davon ab.
- **Bayesian Dropout:** Bei $n=10$ ist Unsicherheitsquantifizierung sinnvoll. MC-Dropout bleibt zur Inferenz aktiv; $N=10$ Forward Passes liefern eine mittlere Segmentierung und eine voxelweise Varianzkarte (nur hpt_dropout; alle anderen Experimente evaluieren deterministisch). Hohe Varianz an Grenzen ist erwartet, hohe Varianz in Muskelzentren weist auf Modellprobleme hin.

Architektur: Encoder-Decoder mit Skip Connections, base_channels=16, depth=4, Dropout $p=0.3$. Kompakt gewählt, da grössere Netze bei 6–7 Trainingsfällen überanpassen. Input 1 Kanal, Output 9-Klassen-Softmax. Patch-Training $128 \times 128 \times 32$, Batch 2, Mixed Precision.

Experimentelle Sequenz:

3. **Overfit-Validierung:** Single-Subject-Overfit (Proband 512, dropout=0, $lr=1e-3$, 300 Ep.) bestätigt Pipeline und Modellkapazität, bevor Generalisierung getestet wird (Schwelle Dice ≥ 0.90).
4. **Baseline:** Dice Loss (ohne BG), Adam $lr=0.0001$, 100 Ep., dropout=0.3, keine Augmentation, foreground-zentriertes Sampling.
5. **Fünf isolierte HPT-Experimente**, je ein Parameter gegenüber der Baseline geändert ([Details in Anhang, Tab. A1](#)).

Evaluation: Primärmetrik Macro-Dice über Klassen 1–8 (BG ausgeschlossen, da ~82% der Voxel), gemittelt über 3 Folds $\pm$ Std. Sliding-Window-Inferenz mit 50% Überlapp. CC-Postprocessing (Connected-Component): Eine zusammenhängende Komponente ist eine Gruppe direkt benachbarter Voxel derselben Klasse; pro Klasse wird nur die grösste solche 3D-Komponente behalten und kleinere, isolierte Fehlsegmente werden verworfen, da ein Muskel anatomisch ein einziges zusammenhängendes Volumen bildet. ECE wird nur für hpt_dropout ($N=10$ MC-Samples) berechnet.

4.6 Most Relevant Results

Overfit-Validierung: Der Single-Subject-Overfit (Proband 512) erreicht Dice 0.9011 bei Epoche 244, knapp über der 0.90-Schwelle. Die langsame Konvergenz ([Anhang, Abb. 3 und 4](#)) zeigt, dass die 100-Epochen-CV-Runs budgetlimitiert und nicht voll konvergiert sind. Pipeline und Kapazität sind bestätigt.

Dice-Übersicht ([Anhang, Tab. A2](#)): hpt_combined erzielt mit 0.308 das höchste Ergebnis (+0.074 vs. Baseline 0.234, +0.089 mit CC), zeigt aber die grösste Fold-Varianz ([Anhang, Abb. 5](#)). hpt_focal (0.266) übertrifft die Baseline ebenfalls; hpt_augmentation und hpt_dropout liegen 40–46% darunter.

Per-Klassen-Dice (Anhang, [Tab. A3](#) und [Abb. 6](#)): hpt_combined dominiert beim Quadrizeps (VL 0.743, VI 0.716, VM 0.415), hpt_focal ist bei den Hamstrings stärker (BfLH ~0.26, ST ~0.37); BfSH wird von keinem Experiment zuverlässig segmentiert.

Confusion-Matrix (zeilen-normiert, [Anhang, Abb. 7](#)): In der Baseline kollabieren Hamstrings in den Hintergrund oder werden als Quadrizeps prädiagnostiziert (BfSH 0% korrekt). hpt_focal hebt BfSH auf 55% korrekt, senkt aber VM von 80% auf 51%. hpt_combined erreicht beim Quadrizeps 89–94% korrekte Voxel, BfSH bleibt jedoch bei 0% (35% als VM, 36% als SM verwechselt).

CC-Postprocessing (hpt_combined): CC hilft dem Quadrizeps deutlich (VM 0.42→0.53, VI 0.72→0.82), schadet aber den Hamstrings (BfLH 0.04→0.01), da deren grösste Komponente falsch liegt. Der Gewinn (+0.047) ist asymmetrisch; qualitative Vorhersagen in [Anhang, Abb. 8 und 9](#) veranschaulichen den Unterschied.

ECE (hpt_dropout, N=10): Mean ECE = 0.070 über 3 Folds — leicht überconfident, aber nicht stark fehlkalibriert.

5 Discussion

RQ1 (Dice ≥ 0.60): nicht erreicht. Das beste Ergebnis ist 0.308 (hpt_combined) bzw. 0.355 mit CC — rund 0.25 unter dem Ziel. Der Overfit (0.90 auf einem Probanden) belegt ausreichende Modellkapazität; der Engpass ist die Datenbasis. Mit 6–7 Trainingsfällen pro Fold kann das Netz keine cross-subject-stabilen Klassengrenzen lernen, da anatomische Variabilität (Muskelgrösse, -lage, -form) nicht abgedeckt ist. Ein Dice ≥ 0.60 setzt realistisch 30–50 annotierte Probanden oder Transfer Learning (z.B. nnU-Net) voraus. Für den direkten klinischen Einsatz sind die Ergebnisse noch nicht geeignet, der Entwicklungsprozess ist jedoch vollständig und methodisch korrekt.

RQ2 (+0.03): erfüllt. hpt_focal (+0.032) und hpt_combined (+0.074) übertreffen die Baseline signifikant; mit CC steigen die Werte auf +0.028 bzw. +0.089. RQ2 ist mit und ohne Postprocessing erfüllt.

Drei Fehlermodi — eine Evolution: Die Confusion-Matrix-Analyse ([Anhang, Abb. 7](#)) zeigt qualitativ verschiedene Fehlermuster, die einen Lernpfad beschreiben:

- **Baseline:** Hamstrings kollabieren in den Hintergrund oder werden als Quadrizeps klassifiziert — die Region wird lokalisiert, die Grenzen nicht.
- **hpt_focal:** Der BG-Kollaps verschwindet, aber 43–61% der Hamstring-Voxel landen beim falschen Muskel. Focal Loss erzwingt Foreground, löst aber die Klassentrennung nicht.
- **hpt_combined:** Quadrizeps erreicht 89–94% korrekte Voxel, doch BfSH bleibt bei 0%. Klassen-balanciertes Sampling stabilisiert den Quadrizeps, reicht für die schwierigsten Hamstrings aber nicht.

Dieser Übergang von BG-Kollaps über Inter-Muskel-Verwechslung zu selektiver Klassen-Dominanz ist die zentrale diagnostische Erkenntnis und wäre durch Dice-Scores allein nicht sichtbar gewesen.

Fehlgeschlagene Experimente: hpt_augmentation verschlechterte sich um -0.108. Nachträglich wurde ein anatomischer Bug identifiziert: Axis-0-Flip vertauscht VL↔VM, Axis-1-Flip RF↔Hamstrings, rot90 zerstört die Anatomie — das Modell trainierte auf

widersprüchlichen Labels. Die korrigierte Variante (nur Axis-2-Flip + Jitter) floss in hpt_combined ein, erklärt dessen Gewinn aber nicht allein; dominant sind klassen-balanciertes Sampling und Focal-Tversky-Loss. hpt_dropout p=0.5 scheiterte, da starke Regularisierung im datenknappen Regime zu wenig Information aus den Daten lässt.

Klinische Einordnung: VL (92% korrekt) und SM (73%) erreichen bereits klinisch relevante Genauigkeiten. Für selektives Volumen-Monitoring einzelner Muskeln wäre ein Einsatz denkbar; für alle acht Klassen gleichzeitig ist mehr Trainingsdaten nötig.

6 Reflection

Die Overfit-Validierung (Dice 0.90, Epoche 244) war unverzichtbar: Sie belegte die Korrektheit der Pipeline und die Budget-Limitierung der CV-Runs. Der überraschendste Befund war die Evolution der Fehlermodi (BG-Kollaps → Inter-Muskel-Verwechslung → selektive Dominanz), nur durch die Confusion-Matrix sichtbar. Rückblickend hätte anatomisch-bewusste Augmentation von Beginn an Priorität haben sollen. Empfehlung: mindestens 20 Probanden, Transfer Learning (nnU-Net) und konfidenzgewichtetes CC.

Selbstbeurteilung: Als Stärken sehen wir das Methodendesign, die Evaluation und die analytische Einordnung — die isolierten Ein-Parameter-Experimente, die vollständig und ehrlich reportierten Metriken inklusive Fehlschläge sowie die diagnostische Herausarbeitung der drei Fehlermodi. Datengrundlage und technische Umsetzung beurteilen wir zurückhaltender: n=10 limitiert strukturell, und der Augmentation-Bug fiel erst nachträglich auf. Anders machen würden wir den Modellvergleich zusätzlich mit einem statistischen Foldtest absichern, qualitative Vorhersage-Overlays ergänzen und die uneinheitliche Metrik-Benennung im Logging früher bereinigen.

A Anhang

A.1 Abbildungen




Abbildung 1 - Slice Coverage



Abbildung 2 - Verarbeitungs-Pipeline der 3D-Segmentierung




Abbildung 3 – Overfit Loss




Abbildung 4 - Overfit Dice




Abbildung 5 - Dice overview




Abbildung 6 - Dice per class

Abb. A6 – Confusion-Matrix (Foreground-Voxel, Zeilen-normiert in %)




Abbildung 7 - Confusion Matrix




Abbildung 8 - Vorhersagen Baseline (Proband 512, Fold 0)




Abbildung 9 - Vorhersagen *hpt_combined* (Proband 512, Fold 0)

Lesehilfe zu Abb. 8 und 9: Beide zeigen Proband 512 (Fold 0) in sechs repräsentativen Axialschnitten (Zeilen = verschiedene Z-Positionen am Oberschenkel). Spalten: links Water-

MRI (Modelleingabe), Mitte Ground Truth als Farbüberlagerung, rechts Modell-Vorhersage. Farbkodierung der acht Muskelklassen: VL violett/blau, RF orange, VM rosa, VI gelb, Hamstrings (BfSH, BfLH, ST, SM) türkis/grün, Hintergrund schwarz. In der Baseline (Abb. 8) kollabieren die Hamstrings im hinteren Querschnitt entweder zu Hintergrund oder werden als Quadrizeps eingefärbt. Bei hpt_combined (Abb. 9) ist der vordere Quadrizeps gut und nahe an der Ground Truth segmentiert, während die Hamstrings hinten als zusammenhängender Türkis-Block ohne klare Klassentrennung erscheinen.

A.2 Tabellen

Tab. A1: HPT-Experimente, jeweils ein Parameter gegenüber der Baseline geändert.

Experiment	Änderung vs. Baseline
hpt_focal	Dice + Focal Loss (Hamstrings $\alpha=3-4$, BG $\alpha=0.1$, $\gamma=2.0$)
hpt_augmentation	+ Axis-Flips + Intensitätsjitter (Bug, s. Diskussion)
hpt_lr_scheduler	+ Cosine Annealing + Early Stopping (Geduld 20 Ep.)
hpt_dropout	Dropout $p=0.5$ + ECE-Bewertung (N=20 MC-Samples)
hpt_combined	Focal-Tversky ($\alpha=0.3$, $\beta=0.7$, $\gamma=0.75$) + klassen-balanciertes Sampling, 200 Ep.

Tab. A2: Dice-Übersicht, 3-Fold CV, Hintergrund ausgeschlossen. Beste Zeile hervorgehoben.

Experiment	Fold 0	Fold 1	Fold 2	Mean $\pm$ Std	mit CC
Baseline	0.260	0.244	0.197	0.234 $\pm$ 0.026	0.266
hpt_focal	0.234	0.255	0.308	0.266 $\pm$ 0.031	0.294
hpt_lr_scheduler	0.227	0.210	0.204	0.213 $\pm$ 0.010	0.254
hpt_dropout $p=0.5$	0.131	0.140	0.119	0.130 $\pm$ 0.009	0.154
hpt_augmentation	0.147	0.095	0.135	0.126 $\pm$ 0.022	0.156
hpt_combined	0.391	0.244	0.288	0.308 $\pm$ 0.061	0.355

Tab. A3: Per-Klassen-Dice (Mittel über Val-Probanden).

Muskel	Baseline	hpt_focal	hpt_combined
VL_R	~0.58	~0.53	0.743
RF_R	~0.10	~0.15	0.135
VM_R	~0.28	~0.29	0.415
VI_R	~0.70	~0.41	0.716
BfSH_R	~0.02	~0.11	0.000
BfLH_R	~0.00	~0.26	0.044
ST_R	~0.00	~0.37	0.292
SM_R	~0.00	~0.12	0.182